

# Regresja liniowa

Dominik Lau

3 marca 2023

## 1 Wzór

Regresja liniowa to technika uczenia z **nadzorem**. Mamy dane  $X, Y$ .

$$X = \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ x_3 & 1 \\ \dots & \dots \\ x_n & 1 \end{bmatrix}, Y = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \dots \\ y_n \end{bmatrix}$$

jedynki w drugiej kolumnie  $X$  przydadzą się do skrócenia zapisu. Chcemy wyznaczyć prostą  $y = ax_1 + b$ , która minimalizuje

$$MSE = \frac{1}{n} \sum_{x \in X, y \in Y} (y - ax_0 - b)^2$$

gdzie  $n$  to liczba danych a  $x_0$  to pierwsza współrzędna wektora kolumnowego  $\vec{x}$  (jednej kolumny macierzy  $X$ ) więc musimy policzyć **gradient** ale najpierw uproszczenie zapisu:

$$y = ax_0 + b = [a, b] \cdot \begin{bmatrix} x_0 \\ 1 \end{bmatrix} = (\vec{\theta})^T \vec{x}$$

teraz liczymy gradient czyli pochodną po wektorze  $\theta$  z naszej funkcji błędu

$$\nabla = \frac{\partial}{\partial \theta} ((y - \theta x)^2) = -2x(y - \theta x)$$

z ostatniej równości dostajemy wartość **gradientu**, żeby znaleźć minimum (błędu) przyrównujemy do 0

$$-2x(y - \theta x) = 0$$

przechodząc na cały zbiór, czyli na całe macierze (**uwaga!** należy tu brać pod uwagę wymiary wszystkiego, jeszcze je zapiszę poniżej)

$$\dim X = n \times 2$$

$$\dim Y = n \times 1$$

$$\dim \theta = 1 \times 2$$

$$-2X^T(Y - X\theta^T) = 0$$

$$X^TY - X^TX\theta^T = 0$$

$$\theta^T = (X^TX)^{-1}X^TY$$

stąd liczymy  $\theta$ , które minimalizuje nasz błąd i są to współczynniki szukanej prostej

## 2 Spadek po gradiencie

### 2.1 Działanie

Czasem nie jesteśmy w stanie w tak łatwy sposób znaleźć wzoru na minima. Wówczas korzystamy z metody spadku po gradiencie. Zapisujemy gradient:

$$\nabla = -2x(y - \theta x)$$

w wersji macierzowej

$$\nabla = -2X^T(Y - X\theta^T)$$

losujemy wartości  $\theta$  i wykonujemy  $K$  (np. 100 iteracji) z każdą iteracją poprawiając  $\theta$  zgodnie ze wzorem

$$\theta_{i+1} = \theta_i - \kappa \nabla$$

gdzie  $\kappa$  to współ. kroku, który daje nam większą dokładność parametru (musi być bardzo mały typu 0.001). Iterując w ten sposób przesuwamy się przeciwnie do gradientu co w efekcie zmniejsza wartość funkcji.

### 2.2 Standaryzacja

Standaryzacja służy do zbliżenia do siebie wartości (tak, żeby  $VX = 0$ ) dzięki czemu metoda spadku po gradiencie działa w mniejszej liczbie iteracji. Żeby ustandaryzować dane trzeba dla  $X, Y$  obliczyć wartości  $X_s, Y_s$  zgodnie ze wzorem

$$X_s = \frac{X - EX}{\sigma_X}$$

$$Y_s = \frac{Y - EY}{\sigma_Y}$$

$E$  - średnia (**operator!**)  
 $\sigma = \sqrt{V}$  - odchylenie standardowe  
 $V$  - wariancja (**operator!**)

### 3 Polecenia

Dla danych o samochodach ( $X$ - masa,  $Y$  - spalanie):

1. wyznaczyć  $\theta$  ze wzoru (3p)
  - (a) policzyć ze wzoru  $\theta$
  - (b) dla wyznaczonego  $\theta$  policzyć  $MSE$
2. wyznaczyć  $\theta$  metodą spadku po gradiencie
  - (a) standaryzacja danych (1p)
  - (b) wyznaczyć  $\theta$  (1p)